深度学习进阶面试笔记

根据深度学习花书整理

2026 年 3 月 17 日

目录

1 广播机制 **4**

1.1 数学本质 4

1.2 工程易错点 4

1.3 前沿应用 4

2 正交矩阵的行向量标准正交性 **5**

2.1 数学推导 5

2.2 工程细节 5

2.3 实践与前沿 5

3 矩阵的特征分解与实对称矩阵 **5**

3.1 谱定理 5

3.2 证明思路 6

3.3 工程易错 6

3.4 前沿 6

4 奇异值分解 **6**

4.1 定义与几何意义 6

4.2 与特征分解的关系 7

4.3 工程易错 7

4.4 前沿应用 7

5 Moore-Penrose 伪逆 **7**

5.1 定义与 SVD 形式 7

5.2 几何意义与性质 7

5.3 工程易错 8

5.4 前沿 8

6 主成分分析 **8**

6.1 数学推导 8

6.2 工程易错 8

6.3 前沿 8

7 Multinoulli 分布 **9**
7.1 定义 9
7.2 与多项分布的关系 9
7.3 深度学习应用 9
7.4 前沿技巧 9

8 参数化分布的精度控制 **9**
8.1 指数族视角 9
8.2 工程实践 10
8.3 易错点 10

9 Laplace 分布 **10**
9.1 定义与性质 10
9.2 与正则化的联系 11
9.3 工程易错 11
9.4 前沿 11

10 Dirac 分布 **11**
10.1 定义 11
10.2 应用 11
10.3 工程易错 11

11 Logistic Sigmoid 饱和现象 **12**
11.1 饱和定义 12
11.2 工程对策 12

12 softplus 函数 **12**
12.1 定义 12
12.2 数值稳定实现 12
12.3 应用 12

13 雅可比行列式与概率密度变换 **13**
13.1 变量变换公式 13
13.2 工程难点 13
13.3 前沿：标准化流 13

14 Softmax 与 Log-Softmax 的数值稳定性 **13**
14.1 上溢/下溢问题 13
14.2 标准技巧 14
14.3 工程实现 14

15 病态条件与条件数 **14**
15.1 定义 14
15.2 工程对策 14

16 牛顿法原理 **15**
16.1 推导 15
16.2 收敛性 15
16.3 工程难点与改进 15

17 KKT 条件 **15**
17.1 一般形式 15
17.2 几何意义 16
17.3 工程应用 16

18 VC 维 **16**
18.1 定义 16
18.2 泛化理论 16
18.3 深度学习悖论 17
18.4 前沿复杂度度量 17

19 k 折交叉验证 **17**
19.1 方法 17
19.2 选择 k 的考量 17
19.3 工程易错 17
19.4 前沿 17

20 最大后验估计 **17**
20.1 定义 17
20.2 与正则化的关系 18
20.3 工程易错 18
20.4 前沿 18

21 支持向量机 **18**
21.1 原始问题与对偶 18
21.2 核技巧 18
21.3 工程易错 19
21.4 前沿 19

22 K-均值聚类 **19**
22.1 算法 19
22.2 工程易错 19
22.3 前沿 19

23 局部核、流形假设与流形学习 **20**
23.1 局部核 20
23.2 流形假设 20
23.3 流形学习算法 20
23.4 工程易错 20
23.5 前沿与深度学习 20

1 广播机制

1.1 数学本质

定义 1.1 (广播兼容性)**.** *广播 (Broadcasting) 是 NumPy、PyTorch 等张量库中用于形状不同数组之间逐元素运算的机制。设张量 $\boldsymbol{A}$ 和 $\boldsymbol{B}$ 的形状分别为 $\boldsymbol{s}_A = (d_1^A, d_2^A, \ldots, d_m^A)$ 和 $\boldsymbol{s}_B = (d_1^B, d_2^B, \ldots, d_n^B)$，则它们可广播当且仅当：从尾部维度开始对齐后，每个对应维度满足以下条件之一：*

1. *两维度长度相等，即 $d_i^A = d_i^B$；*
2. *其中之一为 1，即 $d_i^A = 1$ 或 $d_i^B = 1$；*
3. *其中之一缺失（视为 1）。*

定理 1.1 (广播等价表示)**.** *若张量 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ 与向量 $\boldsymbol{b} \in \mathbb{R}^n$ 可广播，则存在等价表示：*

$$\boldsymbol{A} + \boldsymbol{b} = \boldsymbol{A} + \mathbf{1}_{m\times 1} \cdot \boldsymbol{b}^T$$

其中 $\mathbf{1}_{m\times 1}$ 为全 1 列向量，$\boldsymbol{b}$ 被逻辑复制 m 行。

证明. 设 $\boldsymbol{A} = [a_{ij}]$，$\boldsymbol{b} = [b_j]$，则 $(\boldsymbol{A} + \boldsymbol{b})_{ij} = a_{ij} + b_j$。另一方面：

$$(\mathbf{1}_{m\times 1} \cdot \boldsymbol{b}^T)_{ij} = \sum_k (1)_{ik} (b^T)_{kj} = b_j$$

故 $(\boldsymbol{A} + \mathbf{1}_{m\times 1} \cdot \boldsymbol{b}^T)_{ij} = a_{ij} + b_j$，与广播结果一致。 □

1.2 工程易错点

- **维度理解错误**：形状为 $(3,)$ 的向量被视为 $(1,3)$，与 $(3,1)$ 矩阵相加得到 $(3,3)$，而非报错。
- **内存与性能**：广播通过步长 (stride) 实现逻辑扩展，不占用额外内存，但若后续运算涉及大维度扩张（如将 $(1,1000)$ 广播到 $(10000,1000)$），仍会导致大量计算，需注意内存带宽。
- **自动微分**：广播的反向传播需对广播维度进行求和。设 $\boldsymbol{y} = \boldsymbol{x} + \boldsymbol{b}$，其中 $\boldsymbol{x} \in \mathbb{R}^{m\times n}$，$\boldsymbol{b} \in \mathbb{R}^n$，则：

  $$\frac{\partial L}{\partial \boldsymbol{b}} = \sum_{i=1}^{m} \left(\frac{\partial L}{\partial \boldsymbol{y}} \right)_{i,:}$$

  这是因为前向传播中 $\boldsymbol{b}$ 被复制了 m 次，反向传播需累加梯度贡献。

定理 1.2 (广播反向传播规则)**.** *设张量 $\boldsymbol{X} \in \mathbb{R}^{d_1\times\cdots\times d_k}$ 通过广播得到 $\boldsymbol{Y} \in \mathbb{R}^{d_1'\times\cdots\times d_k'}$（其中部分维度 $d_i = 1$ 被扩展为 d_i'），则反向传播时：*

$$\frac{\partial L}{\partial \boldsymbol{X}} = reshape\left(\sum_{broadcast\ dims} \frac{\partial L}{\partial \boldsymbol{Y}}, \boldsymbol{X}\text{'s shape} \right)$$

1.3 前沿应用

在 Transformer 中，多头注意力的偏置项常通过广播加到每个头的输出上。此外，混合精度训练中需注意广播导致的数值范围变化。

2 正交矩阵的行向量标准正交性

2.1 数学推导

定义 2.1 (正交矩阵)**.** 若矩阵 $\boldsymbol{Q} \in \mathbb{R}^{n\times n}$ 满足 $\boldsymbol{Q}^T\boldsymbol{Q} = \boldsymbol{I}$，则称 $\boldsymbol{Q}$ 为正交矩阵。

定理 2.1 (正交矩阵的行列正交性)**.** 若 $\boldsymbol{Q}$ 为正交矩阵，则：

1. $\boldsymbol{Q}$ 可逆且 $\boldsymbol{Q}^{-1} = \boldsymbol{Q}^T$；
2. $\boldsymbol{Q}\boldsymbol{Q}^T = \boldsymbol{I}$，即行向量也标准正交；
3. $|\det(\boldsymbol{Q})| = 1$。

证明. 由 $\boldsymbol{Q}^T\boldsymbol{Q} = \boldsymbol{I}$，根据行列式性质：

$$\det(\boldsymbol{Q}^T\boldsymbol{Q}) = \det(\boldsymbol{Q}^T)\det(\boldsymbol{Q}) = \det(\boldsymbol{Q})^2 = \det(\boldsymbol{I}) = 1$$

故 $\det(\boldsymbol{Q}) = \pm 1 \neq 0$，$\boldsymbol{Q}$ 可逆。左乘 $\boldsymbol{Q}^{-1}$ 得 $\boldsymbol{Q}^T = \boldsymbol{Q}^{-1}$，故 $\boldsymbol{Q}\boldsymbol{Q}^T = \boldsymbol{Q}\boldsymbol{Q}^{-1} = \boldsymbol{I}$。 □

注 2.1. 正交矩阵的行向量与列向量均构成 $\mathbb{R}^n$ 的标准正交基。

2.2 工程细节

命题 2.2 (非方阵的正交性)**.** 对于非方阵 $\boldsymbol{U} \in \mathbb{R}^{m\times n}$（假设 $m > n$），若满足 $\boldsymbol{U}^T\boldsymbol{U} = \boldsymbol{I}_n$，则：

1. 列向量标准正交；
2. $\boldsymbol{U}\boldsymbol{U}^T \neq \boldsymbol{I}_m$，行向量不一定正交；
3. $\boldsymbol{U}$ 是等距映射，保持向量范数：$\|\boldsymbol{U}\boldsymbol{x}\|_2 = \|\boldsymbol{x}\|_2$。

定理 2.3 (正交矩阵的数值稳定性)**.** 正交矩阵 $\boldsymbol{Q}$ 的 2-范数条件数 $\kappa_2(\boldsymbol{Q}) = 1$，故乘法运算不放大误差：

$$\frac{\|\delta\boldsymbol{y}\|}{\|\boldsymbol{y}\|} \leq \kappa(\boldsymbol{Q})\frac{\|\delta\boldsymbol{x}\|}{\|\boldsymbol{x}\|} = \frac{\|\delta\boldsymbol{x}\|}{\|\boldsymbol{x}\|}$$

2.3 实践与前沿

- **正交初始化**：RNN 中权重矩阵初始化为正交矩阵可缓解梯度消失/爆炸。实现时可用 QR 分解对随机高斯矩阵分解得到正交基。
- **神经网络正交性**：近期研究（如 Orthogonal Regularization）在训练中施加正交约束，可提高模型泛化性和鲁棒性。

3 矩阵的特征分解与实对称矩阵

3.1 谱定理

定理 3.1 (谱定理)**.** 设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为实对称矩阵，则 $\boldsymbol{A}$ 可正交对角化：

$$\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^T, \quad \boldsymbol{Q}^T\boldsymbol{Q} = \boldsymbol{I},\ \boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \ldots, \lambda_n),\ \lambda_i \in \mathbb{R}.$$

其中 $\lambda_1, \ldots, \lambda_n$ 为 $\boldsymbol{A}$ 的特征值，$\boldsymbol{Q}$ 的列为对应的正交特征向量。

定理 3.2 (实对称矩阵的性质)**.** 设 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ 为实对称矩阵，则：

1. 所有特征值均为实数；
2. 不同特征值对应的特征向量正交；
3. $\boldsymbol{A}$ 的正惯性指数等于正特征值个数，负惯性指数等于负特征值个数。

3.2 证明思路

谱定理证明要点. 1. **特征值为实数**：设 $\boldsymbol{A}\boldsymbol{v} = \lambda\boldsymbol{v}$，$\boldsymbol{v} \neq 0$。取共轭转置：

$$\bar{\lambda}\bar{\boldsymbol{v}}^T\boldsymbol{v} = (\boldsymbol{A}\boldsymbol{v})^H\boldsymbol{v} = \boldsymbol{v}^H\boldsymbol{A}^H\boldsymbol{v} = \boldsymbol{v}^H\boldsymbol{A}\boldsymbol{v} = \lambda\boldsymbol{v}^H\boldsymbol{v}$$

由 $\boldsymbol{v}^H\boldsymbol{v} > 0$ 得 $\bar{\lambda} = \lambda$，故 $\lambda \in \mathbb{R}$。

2. **特征向量正交**：设 $\boldsymbol{A}\boldsymbol{v}_1 = \lambda_1\boldsymbol{v}_1$，$\boldsymbol{A}\boldsymbol{v}_2 = \lambda_2\boldsymbol{v}_2$，$\lambda_1 \neq \lambda_2$。则：

$$\lambda_1\boldsymbol{v}_1^T\boldsymbol{v}_2 = (\boldsymbol{A}\boldsymbol{v}_1)^T\boldsymbol{v}_2 = \boldsymbol{v}_1^T\boldsymbol{A}^T\boldsymbol{v}_2 = \boldsymbol{v}_1^T\boldsymbol{A}\boldsymbol{v}_2 = \lambda_2\boldsymbol{v}_1^T\boldsymbol{v}_2$$

因 $\lambda_1 \neq \lambda_2$，故 $\boldsymbol{v}_1^T\boldsymbol{v}_2 = 0$。

3. **Schur 分解**：通过 Schur 分解 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{T}\boldsymbol{Q}^T$（$\boldsymbol{T}$ 为上三角），由对称性得 $\boldsymbol{T} = \boldsymbol{T}^T$，故 $\boldsymbol{T}$ 为对角矩阵。

□

3.3 工程易错

- 数值求解特征值常用 QR 算法，对病态矩阵需注意精度。
- 特征值分解仅对方阵定义，SVD 则适用于任意矩阵。

3.4 前沿

Hessian 矩阵的特征值分布揭示了损失景观的曲率。例如，在神经网络中，Hessian 的最大特征值远大于最小特征值，导致病态，需用自适应优化器（如 Adam）缓解。

4 奇异值分解

4.1 定义与几何意义

定理 4.1 (奇异值分解). 任意矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$（秩为 r）可分解为：

$$\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T = \sum_{i=1}^{r}\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^T$$

其中：

- $\boldsymbol{U} \in \mathbb{R}^{m\times m}$ 为左奇异向量矩阵，正交；
- $\boldsymbol{V} \in \mathbb{R}^{n\times n}$ 为右奇异向量矩阵，正交；
- $\boldsymbol{\Sigma} \in \mathbb{R}^{m\times n}$ 为对角矩阵，奇异值 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$，$\sigma_{r+1} = \cdots = \sigma_{\min(m,n)} = 0$。

注 4.1 (几何解释). *SVD* 将线性变换分解为三个步骤：

1. $\boldsymbol{V}^T$：在输入空间旋转，将输入映射到奇异向量方向；
2. $\boldsymbol{\Sigma}$：沿各主方向缩放，σ_i 为第 i 个主方向的拉伸因子；
3. $\boldsymbol{U}$：在输出空间旋转。

因此，*SVD* 揭示了线性变换的本质几何结构。

4.2 与特征分解的关系

定理 4.2 (SVD 与特征值的关系)**.** 设 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T$ 为 $\boldsymbol{A}$ 的 *SVD*，则：

$$\boldsymbol{A}^T\boldsymbol{A} = \boldsymbol{V}\boldsymbol{\Sigma}^T\boldsymbol{\Sigma}\boldsymbol{V}^T \quad (\text{特征值 } \sigma_i^2\text{，特征向量构成 } \boldsymbol{V})$$
$$\boldsymbol{A}\boldsymbol{A}^T = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^T\boldsymbol{U}^T \quad (\text{特征值 } \sigma_i^2\text{，特征向量构成 } \boldsymbol{U})$$

推论 4.3 (低秩近似)**.** 设 $\boldsymbol{A}$ 的秩为 r，取前 $k < r$ 个奇异值，则 *Eckart-Young* 定理保证：

$$\boldsymbol{A}_k = \sum_{i=1}^{k} \sigma_i \boldsymbol{u}_i \boldsymbol{v}_i^T = \arg\min_{\operatorname{rank}(\boldsymbol{B}) \le k} \|\boldsymbol{A} - \boldsymbol{B}\|_F$$

4.3 工程易错

- 计算 $\boldsymbol{A}^T\boldsymbol{A}$ 再求特征分解可能丢失精度（平方导致动态范围扩大），直接用 SVD 更稳定。
- 截断 SVD 在降维中需注意保留的奇异值个数，常用能量阈值（如保留 90%方差）。

4.4 前沿应用

- 低秩近似压缩模型：将权重矩阵 $\boldsymbol{W}$ 近似为 $\boldsymbol{U}_k\boldsymbol{\Sigma}_k\boldsymbol{V}_k^T$，减少参数量。
- 推荐系统中的矩阵分解（如 FunkSVD）。
- 神经网络可解释性：通过 SVD 分析特征表示的主方向，发现语义概念。

5 Moore-Penrose 伪逆

5.1 定义与 SVD 形式

定义 5.1 (Moore-Penrose 伪逆)**.** 对于任意矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$，其伪逆 $\boldsymbol{A}^+ \in \mathbb{R}^{n\times m}$ 是唯一满足以下 *Penrose* 条件的矩阵：

$$\boldsymbol{A}\boldsymbol{A}^+\boldsymbol{A} = \boldsymbol{A} \tag{1}$$
$$\boldsymbol{A}^+\boldsymbol{A}\boldsymbol{A}^+ = \boldsymbol{A}^+ \tag{2}$$
$$(\boldsymbol{A}\boldsymbol{A}^+)^T = \boldsymbol{A}\boldsymbol{A}^+ \tag{3}$$
$$(\boldsymbol{A}^+\boldsymbol{A})^T = \boldsymbol{A}^+\boldsymbol{A} \tag{4}$$

定理 5.1 (伪逆的 SVD 计算)**.** 设 $\boldsymbol{A} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T$ 为 *SVD*，则：

$$\boldsymbol{A}^+ = \boldsymbol{V}\boldsymbol{\Sigma}^+\boldsymbol{U}^T$$

其中 $\boldsymbol{\Sigma}^+$ 将非零奇异值取倒数并转置：$(\boldsymbol{\Sigma}^+)_{ii} = 1/\sigma_i$ 若 $\sigma_i > 0$，否则为 0。

5.2 几何意义与性质

定理 5.2 (伪逆的特殊情况)**.**

1. 若 $\boldsymbol{A}$ 列满秩（$\operatorname{rank}(\boldsymbol{A}) = n$），则 $\boldsymbol{A}^+ = (\boldsymbol{A}^T\boldsymbol{A})^{-1}\boldsymbol{A}^T$（左逆），方程 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$ 的最小二乘解为 $\boldsymbol{x}^* = \boldsymbol{A}^+\boldsymbol{b}$。
2. 若 $\boldsymbol{A}$ 行满秩（$\operatorname{rank}(\boldsymbol{A}) = m$），则 $\boldsymbol{A}^+ = \boldsymbol{A}^T(\boldsymbol{A}\boldsymbol{A}^T)^{-1}$（右逆），给出最小范数解。
3. 若 $\boldsymbol{A}$ 可逆，则 $\boldsymbol{A}^+ = \boldsymbol{A}^{-1}$。

定理 5.3 (最小范数最小二乘解)**.** 对于线性系统 $\boldsymbol{A}\boldsymbol{x}=\boldsymbol{b}$（可能无解或有无穷多解），$\boldsymbol{x}^*=\boldsymbol{A}^+\boldsymbol{b}$ 满足：

$$\boldsymbol{x}^*=\arg\min_{\boldsymbol{x}}\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2,\quad \text{且 } \boldsymbol{x}^*=\arg\min_{\boldsymbol{x}\in S}\|\boldsymbol{x}\|_2$$

其中 $S=\{\boldsymbol{x}:\|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|_2 \text{ 最小}\}$。

5.3 工程易错

- 在求解线性系统时，若 $\boldsymbol{A}$ 接近奇异，直接使用伪逆可能放大噪声，需正则化（如 Tikhonov）。
- 实际计算中常用奇异值截断（truncated SVD）来处理秩亏情况。

5.4 前沿

在神经网络中，伪逆用于解耦权重矩阵的分析（如解耦表示学习中的特征）。此外，在优化中，伪逆可用于计算自然梯度（通过 Fisher 信息矩阵的伪逆）。

6 主成分分析

6.1 数学推导

设中心化数据矩阵 $\boldsymbol{X}\in\mathbb{R}^{n\times d}$（样本数为 n，特征维度为 d），样本协方差矩阵为 $\boldsymbol{S}=\frac{1}{n}\boldsymbol{X}^T\boldsymbol{X}$。

定理 6.1 (PCA 的最大方差推导)**.** 寻找投影方向 $\boldsymbol{w}\in\mathbb{R}^d$（$\|\boldsymbol{w}\|_2=1$）使得投影后方差最大：

$$\max_{\boldsymbol{w}}\boldsymbol{w}^T\boldsymbol{S}\boldsymbol{w},\quad s.t.\ \|\boldsymbol{w}\|_2=1$$

由拉格朗日乘子法，构造 $\mathcal{L}(\boldsymbol{w},\lambda)=\boldsymbol{w}^T\boldsymbol{S}\boldsymbol{w}-\lambda(\boldsymbol{w}^T\boldsymbol{w}-1)$。令 $\nabla_{\boldsymbol{w}}\mathcal{L}=0$ 得：

$$\boldsymbol{S}\boldsymbol{w}=\lambda\boldsymbol{w}$$

故最优投影方向为 $\boldsymbol{S}$ 的最大特征值对应的特征向量，投影方差为 λ_1。

定理 6.2 (PCA 的最小重构误差推导)**.** 将数据投影到 k 维子空间后重构，最小化重构误差：

$$\min_{\boldsymbol{W}}\|\boldsymbol{X}-\boldsymbol{X}\boldsymbol{W}\boldsymbol{W}^T\|_F^2,\quad s.t.\ \boldsymbol{W}^T\boldsymbol{W}=\boldsymbol{I}_k$$

最优解为 $\boldsymbol{W}=[\boldsymbol{v}_1,\ldots,\boldsymbol{v}_k]$，即协方差矩阵前 k 大特征值对应的特征向量。

6.2 工程易错

- 未标准化：若特征量纲不同，PCA 受量纲影响，应使用相关矩阵（标准化后协方差）。
- 特征值占比解释方差，但选择 k 时需结合业务理解，不能仅靠阈值。
- PCA 对离群点敏感，可用鲁棒 PCA（如使用 1 范数）。

6.3 前沿

- **概率 PCA**：引入潜变量模型，可用 EM 算法处理缺失值。
- **核 PCA**：通过核技巧捕捉非线性结构，但解释性下降。
- **深度 PCA**：将 PCA 扩展为深度网络（如自编码器），但需注意过完备表示。

7 Multinoulli 分布

7.1 定义

定义 7.1 (Multinoulli 分布)**.** *Multinoulli* 分布（又称范畴分布）描述单次试验中 K 个互斥类别的概率。设随机变量 $\boldsymbol{x} \in \{0,1\}^K$ 为 *one-hot* 向量，概率质量函数为：

$$P(\boldsymbol{x}) = \prod_{k=1}^{K} p_k^{x_k}, \quad \boldsymbol{x} \in \{0,1\}^K,\ \sum_{k=1}^{K} x_k = 1,\ \sum_{k=1}^{K} p_k = 1,\ p_k \geq 0.$$

命题 7.1 (Multinoulli 的统计量)**.** 设 $\boldsymbol{x} \sim \mathit{Multinoulli}(\boldsymbol{p})$，其中 $\boldsymbol{p} = (p_1, \ldots, p_K)$，则：

$$\begin{aligned}
\mathbb{E}[x_k] &= p_k \\
\mathrm{Var}(x_k) &= p_k(1-p_k) \\
\mathrm{Cov}(x_i, x_j) &= -p_i p_j \quad (i \neq j)
\end{aligned}$$

7.2 与多项分布的关系

多项分布是 n 次独立试验的计数结果，Multinoulli 是 $n = 1$ 的特例。

7.3 深度学习应用

定理 7.2 (Softmax 与 Multinoulli 的关系)**.** 在多分类问题中，设真实标签 $y \in \{1, \ldots, K\}$，神经网络输出 *logits* $\boldsymbol{z} \in \mathbb{R}^K$，*softmax* 函数将 *logits* 转换为概率：

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}$$

对于标签 y，其对数似然为：

$$\log P(y|\boldsymbol{z}) = \log p_y = z_y - \log \sum_{j=1}^{K} e^{z_j}$$

交叉熵损失即为负对数似然：$L = -\log P(y|\boldsymbol{z}) = -z_y + \log \sum_j e^{z_j}$。

7.4 前沿技巧

- **Gumbel-Softmax**：用于从离散分布中采样并保持可微，在 VAE 中处理离散潜变量。
- **标签平滑**：将硬目标 y 替换为 $(1-\epsilon)$ 的概率加上 ϵ/K，防止过拟合，提升泛化。

8 参数化分布的精度控制

8.1 指数族视角

定义 8.1 (指数族分布)**.** 若概率分布可表示为以下形式，则称其属于指数族：

$$p(\boldsymbol{x}|\boldsymbol{\eta}) = h(\boldsymbol{x}) \exp\left(\boldsymbol{\eta}^T T(\boldsymbol{x}) - A(\boldsymbol{\eta})\right)$$

其中：

- $\boldsymbol{\eta}$：自然参数（*natural parameter*），控制分布形状；
- $T(\boldsymbol{x})$：充分统计量（*sufficient statistic*）；

- $A(\boldsymbol{\eta})$：对数配分函数（*log-partition function*），保证概率归一化；
- $h(\boldsymbol{x})$：基础测度（*base measure*）。

例 8.1 (正态分布的指数族形式)**.** 设 $X \sim \mathcal{N}(\mu, \sigma^2)$，则：

$$p(x|\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) = \exp\left(\frac{\mu}{\sigma^2}x - \frac{1}{2\sigma^2}x^2 - \frac{\mu^2}{2\sigma^2} - \frac{1}{2}\log(2\pi\sigma^2)\right)$$

自然参数为 $\boldsymbol{\eta} = (\eta_1, \eta_2) = \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right)$，精度为 $\tau = -2\eta_2 = \frac{1}{\sigma^2}$。

定理 8.1 (对数配分函数的性质)**.** $A(\boldsymbol{\eta})$ 的梯度给出充分统计量的期望，*Hessian* 给出协方差：

$$\nabla_{\boldsymbol{\eta}} A(\boldsymbol{\eta}) = \mathbb{E}[T(\boldsymbol{x})], \quad \nabla^2_{\boldsymbol{\eta}} A(\boldsymbol{\eta}) = \mathrm{Var}(T(\boldsymbol{x}))$$

8.2 工程实践

在深度生成模型中，常用神经网络输出分布的参数，如 VAE 中解码器输出均值和对数方差，用 $\log\sigma^2$ 保证方差为正且数值稳定。这相当于用自然参数表示，便于计算 KL 散度。

8.3 易错点

直接输出方差而非对数方差可能导致训练不稳定（方差需为正，但神经网络输出无界）。使用 softplus 或 exp 激活可保证正数，但 exp 可能导致梯度爆炸，故常用对数方差。

9 Laplace 分布

9.1 定义与性质

定义 9.1 (Laplace 分布)**.** *Laplace* 分布（双指数分布）的概率密度函数为：

$$f(x|\mu,b) = \frac{1}{2b}\exp\left(-\frac{|x-\mu|}{b}\right), \quad b > 0$$

其中 μ 为位置参数，b 为尺度参数。

命题 9.1 (Laplace 分布的统计量)**.**

$$\begin{aligned} \mathbb{E}[X] &= \mu \\ \mathrm{Var}(X) &= 2b^2 \\ \text{峰度} &= 3 \quad (\text{正态分布峰度为 } 0\text{，Laplace 更厚尾}) \end{aligned}$$

注 9.1 (与正态分布的比较)**.** 相比正态分布，*Laplace* 分布具有：

- 更尖锐的峰值；
- 更厚的尾部（*kurtosis* > 0）；
- 在原点处不可微。

9.2 与正则化的联系

定理 9.2 (Laplace 先验与 L1 正则化的等价性)**.** *在贝叶斯线性回归中，设似然* $p(\boldsymbol{y}|\boldsymbol{X},\boldsymbol{w}) = \mathcal{N}(\boldsymbol{X}\boldsymbol{w}, \sigma^2\boldsymbol{I})$，*若对参数施加 Laplace 先验* $p(\boldsymbol{w}) = \prod_j \frac{\lambda}{2} e^{-\lambda|w_j|}$，*则 MAP 估计为：*

$$\boldsymbol{w}_{MAP} = \arg\min_{\boldsymbol{w}} \frac{1}{2\sigma^2}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|_2^2 + \lambda \sum_j |w_j|$$

这等价于 L1 正则化（LASSO），导致稀疏解。

证明. 负对数后验为：

$$-\log p(\boldsymbol{w}|\boldsymbol{X},\boldsymbol{y}) \propto \frac{1}{2\sigma^2}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|_2^2 + \lambda\|\boldsymbol{w}\|_1 + \text{const}$$

最小化即得 LASSO 目标。 □

9.3 工程易错

- 最大似然估计中，Laplace 分布的参数估计无闭式解，需数值优化。
- 在深度学习中，Laplace 分布可用于建模重尾噪声（如对抗性扰动）。

9.4 前沿

在贝叶斯深度学习不确定性量化中，可用 Laplace 分布近似后验（Laplace 近似），通过 Hessian 矩阵得到参数的后验协方差。

10 Dirac 分布

10.1 定义

定义 10.1 (Dirac delta 函数)**.** *Dirac delta 函数* $\delta(x)$ *是广义函数，满足以下性质：*

$$\int_{-\infty}^{+\infty} \delta(x - x_0)\, dx = 1, \quad \delta(x - x_0) = 0 \text{ 当 } x \neq x_0$$

对于任意连续函数 f*：*

$$\int_{-\infty}^{+\infty} f(x)\delta(x - x_0)\, dx = f(x_0)$$

注 10.1 (Dirac 分布的意义)**.** *Dirac 分布可视为在* x_0 *处概率质量集中的极限情况，常用于表示确定性变量或退化分布。它不是传统意义上的函数，而是一个测度或分布。*

10.2 应用

- **经验分布**：给定样本 $\{x_i\}$，经验分布 $\hat{p}(x) = \frac{1}{n}\sum_i \delta(x - x_i)$ 是无偏估计。
- **确定性策略**：强化学习中，确定性策略 $\pi(a|s) = \delta(a - \mu(s))$。

10.3 工程易错

Dirac 函数不是普通函数，不能直接代入概率密度运算，需用积分理解。在编程中常用”硬”赋值实现。

11 Logistic Sigmoid 饱和现象

11.1 饱和定义

定义 11.1 (Sigmoid 函数)**.** *Sigmoid 函数定义为：*

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

其导数为 $\sigma'(x) = \sigma(x)(1-\sigma(x))$。

定理 11.1 (Sigmoid 的梯度性质)**.** *1. 最大导数值在 $x=0$ 处取得：$\sigma'(0) = \sigma(0)(1-\sigma(0)) = \frac{1}{4}$；*

2. 当 $|x| \to \infty$ 时，$\sigma'(x) \to 0$（饱和区）。

命题 11.2 (梯度消失的量化分析)**.** *在 L 层深度网络中，若每层激活函数为 sigmoid，反向传播梯度：*

$$\frac{\partial L}{\partial \boldsymbol{W}_1} \propto \prod_{l=1}^{L} \sigma'(\boldsymbol{z}_l) \cdot \boldsymbol{W}_l$$

假设 $\sigma'(\boldsymbol{z}_l) \leq 0.25$ 且 $|\boldsymbol{W}_l| \leq 1$，则梯度以指数速率衰减：$\|\nabla\| \leq 0.25^L$。

11.2 工程对策

- 使用 ReLU 族激活函数，减轻梯度消失。
- 批量归一化使输入保持在非饱和区。
- 在 LSTM 中，sigmoid 用作门控，但通过门结构（加性路径）缓解梯度消失。

12 softplus 函数

12.1 定义

$$\zeta(x) = \log(1+e^x)$$

导数 $\zeta'(x) = \sigma(x)$，值域 $(0, \infty)$。

12.2 数值稳定实现

当 x 很大时，e^x 溢出，常用：

$$\zeta(x) = \max(0, x) + \log(1+e^{-|x|})$$

12.3 应用

- 用于保证方差为正（如 VAE 中输出标准差），比 exp 更平滑。
- 作为 ReLU 的平滑近似，但计算量稍大，不常用作激活。

13 雅可比行列式与概率密度变换

13.1 变量变换公式

定理 13.1 (概率密度变换定理)**.** 设随机向量 $\boldsymbol{x} \in \mathbb{R}^n$ 具有概率密度 $p_{\boldsymbol{x}}(\boldsymbol{x})$，若 $\boldsymbol{y} = g(\boldsymbol{x})$ 为可逆光滑映射，则 $\boldsymbol{y}$ 的概率密度为：

$$p_{\boldsymbol{y}}(\boldsymbol{y}) = p_{\boldsymbol{x}}(g^{-1}(\boldsymbol{y})) \left| \det \frac{\partial g^{-1}(\boldsymbol{y})}{\partial \boldsymbol{y}} \right| = p_{\boldsymbol{x}}(\boldsymbol{x}) \left| \det \frac{\partial g(\boldsymbol{x})}{\partial \boldsymbol{x}} \right|^{-1}$$

其中 $\frac{\partial g}{\partial \boldsymbol{x}}$ 为雅可比矩阵。

证明要点. 由概率守恒：$\int_{\Omega_{\boldsymbol{y}}} p_{\boldsymbol{y}}(\boldsymbol{y})\, d\boldsymbol{y} = \int_{\Omega_{\boldsymbol{x}}} p_{\boldsymbol{x}}(\boldsymbol{x})\, d\boldsymbol{x}$。利用变量替换 $d\boldsymbol{y} = \left| \det \frac{\partial g}{\partial \boldsymbol{x}} \right| d\boldsymbol{x}$，即得结论。 □

13.2 工程难点

高维雅可比行列式计算复杂度为 $O(n^3)$，需设计特殊变换使雅可比矩阵为三角或正交：

例 13.1 (可逆变换设计)**.**

- ***NICE***：使用加性耦合层 $\boldsymbol{y}_1 = \boldsymbol{x}_1$，$\boldsymbol{y}_2 = \boldsymbol{x}_2 + m(\boldsymbol{x}_1)$，雅可比行列式为 *1*。
- ***RealNVP***：仿射耦合层 $\boldsymbol{y}_1 = \boldsymbol{x}_1$，$\boldsymbol{y}_2 = \boldsymbol{x}_2 \odot e^{s(\boldsymbol{x}_1)} + t(\boldsymbol{x}_1)$，雅可比为下三角，行列式为对角线乘积。
- ***Glow***：引入可逆 *1x1* 卷积（置换矩阵），行列式可高效计算。

13.3 前沿：标准化流

定义 13.1 (标准化流)**.** 标准化流（*Normalizing Flow*）通过堆叠 K 个可逆变换 $g_1, \ldots, g_K$ 将简单分布 $p_0(\boldsymbol{x}_0)$（如标准正态）映射为复杂分布：

$$\boldsymbol{x}_K = g_K \circ g_{K-1} \circ \cdots \circ g_1(\boldsymbol{x}_0)$$

定理 13.2 (标准化流的对数似然)**.** 通过变量变换公式，对数似然可精确计算：

$$\log p_K(\boldsymbol{x}_K) = \log p_0(\boldsymbol{x}_0) - \sum_{k=1}^{K} \log \left| \det \frac{\partial g_k}{\partial \boldsymbol{x}_{k-1}} \right|$$

这使得标准化流可用于最大似然训练。

14 Softmax 与 Log-Softmax 的数值稳定性

14.1 上溢/下溢问题

注 14.1 (数值问题)**.** 直接计算 $p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$ 存在以下问题：

- **上溢**：当 z_i 过大时，$e^{z_i} \to \infty$，导致 *inf/inf* = *nan*；
- **下溢**：当 z_i 过小时，$e^{z_i} \to 0$，分母可能下溢为 *0*。

14.2 标准技巧

定理 14.1 (Softmax 的数值稳定形式)**.** 设 $m = \max_j z_j$，则：

$$p_i = \frac{e^{z_i - m}}{\sum_j e^{z_j - m}}$$

此形式具有以下性质：

1. 分母至少为 1（最大项贡献 $\frac{e^0}{e^0} = 1$），避免下溢；
2. 指数部分非正（$z_i - m \leq 0$），避免上溢。

推论 14.2 (Log-Softmax 的数值稳定形式)**.**

$$\log p_i = z_i - m - \log \sum_j e^{z_j - m}$$

此形式常用于交叉熵损失和 *NLLLoss* 的实现中。

14.3 工程实现

PyTorch 中 ‘$\log_s oftmax$`和`$softmax$`已内置数值稳定版本。自定义时需注意不要重复减去最大值。

15 病态条件与条件数

15.1 定义

定义 15.1 (条件数)**.** 矩阵 $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ 的条件数定义为：

$$\kappa(\boldsymbol{A}) = \|\boldsymbol{A}\| \cdot \|\boldsymbol{A}^{-1}\|$$

常用的 2-范数条件数为：

$$\kappa_2(\boldsymbol{A}) = \frac{\sigma_{\max}(\boldsymbol{A})}{\sigma_{\min}(\boldsymbol{A})}$$

其中 $\sigma_{\max}$ 和 $\sigma_{\min}$ 分别为最大和最小奇异值。

定理 15.1 (条件数的误差放大效应)**.** 考虑线性系统 $\boldsymbol{A}\boldsymbol{x} = \boldsymbol{b}$，若 $\boldsymbol{b}$ 有扰动 $\delta\boldsymbol{b}$，则解的相对误差满足：

$$\frac{\|\delta\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \leq \kappa(\boldsymbol{A}) \frac{\|\delta\boldsymbol{b}\|}{\|\boldsymbol{b}\|}$$

定理 15.2 (条件数与优化收敛速度)**.** 在凸优化中，设 *Hessian* 矩阵 $\boldsymbol{H}$ 的条件数为 κ，则梯度下降的收敛速度为：

$$f(\boldsymbol{x}_k) - f(\boldsymbol{x}^*) \leq \left(\frac{\kappa - 1}{\kappa + 1}\right)^{2k} (f(\boldsymbol{x}_0) - f(\boldsymbol{x}^*))$$

条件数越大，收敛越慢（呈锯齿状震荡）。

15.2 工程对策

- 预处理（preconditioning）：如使用 Jacobian 预处理器、RMSProp/Adam 等自适应方法隐式调节。
- 在网络中，批归一化可改善 Hessian 的条件数。

16 牛顿法原理

16.1 推导

定理 16.1 (牛顿法迭代公式)**.** 对目标函数 $f(\boldsymbol{x})$ 在当前点 $\boldsymbol{x}_k$ 处作二阶泰勒展开：

$$f(\boldsymbol{x}) \approx f(\boldsymbol{x}_k) + \nabla f(\boldsymbol{x}_k)^T(\boldsymbol{x}-\boldsymbol{x}_k) + \frac{1}{2}(\boldsymbol{x}-\boldsymbol{x}_k)^T\boldsymbol{H}_k(\boldsymbol{x}-\boldsymbol{x}_k)$$

其中 $\boldsymbol{H}_k = \nabla^2 f(\boldsymbol{x}_k)$ 为 *Hessian* 矩阵。令梯度为零得牛顿更新：

$$\boldsymbol{x}_{k+1} = \boldsymbol{x}_k - \boldsymbol{H}_k^{-1}\nabla f(\boldsymbol{x}_k)$$

注 16.1 (牛顿法的几何解释)**.** 牛顿法在每一步用一个二次函数近似原目标函数，并直接跳到该二次函数的最小点。因此，牛顿法是一种二阶方法，利用了曲率信息。

16.2 收敛性

定理 16.2 (牛顿法的局部收敛速度)**.** 设 f 在最优解 $\boldsymbol{x}^*$ 附近二阶连续可微，*Hessian* 在 $\boldsymbol{x}^*$ 处正定，则牛顿法具有局部二次收敛速度：

$$\|\boldsymbol{x}_{k+1} - \boldsymbol{x}^*\| \le C\|\boldsymbol{x}_k - \boldsymbol{x}^*\|^2$$

其中 C 为与 f 二阶导数 *Lipschitz* 常数相关的常数。

注 16.2. 二次收敛意味着接近最优时，每次迭代有效位数翻倍。例如，若当前误差为 10^{-2}，下一步误差约为 10^{-4}，再下一步约为 10^{-8}。

16.3 工程难点与改进

- Hessian 计算和求逆代价高（$O(n^3)$），深度学习参数巨大无法直接使用。
- Hessian 可能不正定，导致更新方向非下降。可用修正牛顿法（如加正则化）。
- 拟牛顿法（BFGS、L-BFGS）用梯度差近似 Hessian，在中等规模问题上有效。
- 自然梯度法利用 Fisher 信息矩阵作为 Hessian 近似，用于神经网络。

17 KKT 条件

17.1 一般形式

定义 17.1 (约束优化问题)**.** 考虑一般约束优化问题：

$$\min_{\boldsymbol{x}} f(\boldsymbol{x}), \quad s.t.\ g_i(\boldsymbol{x}) \le 0\ (i=1,\dots,m),\ h_j(\boldsymbol{x}) = 0\ (j=1,\dots,p)$$

定义 17.2 (拉格朗日函数)**.** 拉格朗日函数定义为：

$$\mathcal{L}(\boldsymbol{x},\boldsymbol{\lambda},\boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{i=1}^{m}\lambda_i g_i(\boldsymbol{x}) + \sum_{j=1}^{p}\nu_j h_j(\boldsymbol{x})$$

其中 $\boldsymbol{\lambda} \ge 0$ 和 $\boldsymbol{\nu}$ 为拉格朗日乘子。

定理 17.1 (KKT 必要条件)**.** 在适当约束规格下（如 *Slater* 条件），若 $\boldsymbol{x}^*$ 为局部最优解，则存在乘子 $\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*$ 满足：

$$\nabla_{\boldsymbol{x}} \mathcal{L}(\boldsymbol{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = 0 \quad \text{(平稳性)} \tag{5}$$

$$\lambda_i^* g_i(\boldsymbol{x}^*) = 0,\ \forall i \quad \text{(互补松弛)} \tag{6}$$

$$g_i(\boldsymbol{x}^*) \leq 0,\ \forall i \quad \text{(原始可行)} \tag{7}$$

$$h_j(\boldsymbol{x}^*) = 0,\ \forall j \quad \text{(等式约束可行)} \tag{8}$$

$$\lambda_i^* \geq 0,\ \forall i \quad \text{(对偶可行)} \tag{9}$$

17.2 几何意义

注 17.1 (互补松弛的几何解释)**.** 互补松弛条件 $\lambda_i^* g_i(\boldsymbol{x}^*) = 0$ 意味着：

- 若约束 g_i 未激活（$g_i(\boldsymbol{x}^*) < 0$），则乘子 $\lambda_i^* = 0$；
- 若乘子 $\lambda_i^* > 0$，则约束激活（$g_i(\boldsymbol{x}^*) = 0$，在边界上）。

只有激活的不等式约束才会影响最优解。

注 17.2 (平稳性的几何解释)**.** 平稳性条件 $\nabla f(\boldsymbol{x}^*) + \sum_i \lambda_i^* \nabla g_i(\boldsymbol{x}^*) + \sum_j \nu_j^* \nabla h_j(\boldsymbol{x}^*) = 0$ 表明：在最优点，目标函数梯度可表示为约束梯度的非负线性组合（对于不等式约束）。

17.3 工程应用

- SVM 的推导中，支持向量对应 $\lambda_i > 0$ 的样本。
- 在神经网络中，约束优化（如权重衰减、梯度裁剪）可视为拉格朗日形式。

18 VC 维

18.1 定义

定义 18.1 (打散与 VC 维)**.**

- **打散**：设假设空间 $\mathcal{H}$ 和样本集 $S = \{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n\}$，若对任意标签分配 $(y_1, \ldots, y_n) \in \{-1, +1\}^n$，都存在 $h \in \mathcal{H}$ 使得 $h(\boldsymbol{x}_i) = y_i$ 对所有 i 成立，则称 $\mathcal{H}$ 打散 S。
- ***VC* 维**：$VCdim(\mathcal{H})$ 定义为 $\mathcal{H}$ 能够打散的最大样本数。

例 18.1 (常见假设空间的 VC 维)**.**

- $\mathbb{R}^d$ 中的线性分类器：$VCdim = d + 1$；
- $\mathbb{R}^2$ 中的轴对齐矩形：$VCdim = 4$；
- 正弦函数族 $\{\sin(\omega x) : \omega > 0\}$：$VCdim = \infty$（可打散任意有限点集）。

18.2 泛化理论

定理 18.1 (VC 维泛化误差界)**.** 设 $\mathcal{H}$ 的 *VC* 维为 d，样本数为 n，则以概率至少 $1 - \delta$，对所有 $h \in \mathcal{H}$：

$$R(h) \leq \hat{R}(h) + \sqrt{\frac{d(\log(2n/d) + 1) + \log(4/\delta)}{n}}$$

其中 $R(h)$ 为期望风险，$\hat{R}(h)$ 为经验风险。

18.3 深度学习悖论

注 18.1 (VC 维的局限)**.** *现代深度网络参数量远超样本数，按传统 VC 理论应严重过拟合，但实际泛化良好。这表明：*

1. *VC 维可能过于悲观，只考虑了假设空间的理论容量；*
2. *训练过程（如 SGD）隐式施加了正则化，偏好某些特定解；*
3. *深度网络的有效容量可能远小于参数量。*

18.4 前沿复杂度度量

- **范数约束**：如谱范数 $\|\boldsymbol{W}\|_2$，用于分析深度网络的 Lipschitz 常数；
- **PAC-Bayes 边界**：考虑参数分布而非单点估计，可得到更紧的泛化界；
- **锐度（Sharpness）**：损失景观在最优解附近的曲率，平坦最小值泛化更好；
- **Rademacher 复杂度**：直接刻画假设空间在数据上的拟合能力。

19 k 折交叉验证

19.1 方法

将数据随机分成 k 份（通常 $k = 5$ 或 10），轮流用 $k-1$ 份训练，1 份验证，取 k 次验证指标的平均。

19.2 选择 k 的考量

- 大 k：训练集更大，模型偏差小，但计算量大，且验证集重叠导致方差大。
- 小 k：反之。经验上 $k = 5$ 或 10 折中。

19.3 工程易错

- 时间序列数据需用前向链（rolling window）避免未来信息泄露。
- 超参数调优后需在独立测试集上评估，否则信息泄露导致乐观估计。

19.4 前沿

深度学习通常只用单次验证（因计算昂贵），但在小数据集或 AutoML 中仍用交叉验证。

20 最大后验估计

20.1 定义

定义 20.1 (MAP 估计)**.** *在贝叶斯框架中，给定数据 $\mathcal{D}$ 和参数先验 $p(\boldsymbol{\theta})$，最大后验估计为：*

$$\boldsymbol{\theta}_{MAP} = \arg\max_{\boldsymbol{\theta}} p(\boldsymbol{\theta}|\mathcal{D}) = \arg\max_{\boldsymbol{\theta}} \left(\log p(\mathcal{D}|\boldsymbol{\theta}) + \log p(\boldsymbol{\theta})\right)$$

注 20.1 (MAP 与 MLE 的关系)**.**

- *MLE（最大似然估计）：$\boldsymbol{\theta}_{MLE} = \arg\max_{\boldsymbol{\theta}} \log p(\mathcal{D}|\boldsymbol{\theta})$，无先验；*
- *MAP 在 MLE 基础上添加先验项 $\log p(\boldsymbol{\theta})$，起到正则化作用；*
- *当 $p(\boldsymbol{\theta})$ 为均匀分布（无信息先验）时，MAP 退化为 MLE。*

20.2 与正则化的关系

定理 20.1 (先验与正则化的对应关系). *1. 高斯先验 $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \boldsymbol{I})$ 对应 L2 正则化:*

$$\log p(\boldsymbol{\theta}) = -\frac{1}{2\sigma^2}\|\boldsymbol{\theta}\|_2^2 + const$$

2. Laplace 先验 $\boldsymbol{\theta}_j \sim Laplace(0, b)$ 对应 L1 正则化:

$$\log p(\boldsymbol{\theta}) = -\frac{1}{b}\|\boldsymbol{\theta}\|_1 + const$$

L1 正则化产生稀疏解，可用于特征选择。

20.3 工程易错

- MAP 仅是点估计，无法量化不确定性。
- 先验的尺度参数（如正则化系数）需通过交叉验证选择。

20.4 前沿

在贝叶斯神经网络中, MAP 训练（即常规训练）常用, 但为了不确定性估计需近似后验（如变分推断、MC Dropout）。

21 支持向量机

21.1 原始问题与对偶

定义 21.1 (线性可分 SVM 原始问题). *寻找最大间隔超平面:*

$$\min_{\boldsymbol{w},b} \frac{1}{2}\|\boldsymbol{w}\|^2, \quad s.t.\ y_i(\boldsymbol{w}^T\boldsymbol{x}_i + b) \geq 1,\ \forall i$$

定理 21.1 (SVM 对偶问题). *原始问题的拉格朗日对偶为:*

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^n \alpha_i - \frac{1}{2}\sum_{i,j=1}^n \alpha_i\alpha_j y_i y_j \boldsymbol{x}_i^T\boldsymbol{x}_j, \quad s.t.\ \alpha_i \geq 0,\ \sum_{i=1}^n \alpha_i y_i = 0$$

定理 21.2 (SVM 分类器). *最优分类器为:*

$$f(\boldsymbol{x}) = \operatorname{sign}\left(\sum_{i=1}^n \alpha_i^* y_i \boldsymbol{x}_i^T\boldsymbol{x} + b^*\right)$$

支持向量为 $\alpha_i^* > 0$ 的样本，只有支持向量影响决策边界。

21.2 核技巧

定义 21.2 (核函数). *核函数 $k: \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ 是满足 Mercer 条件的对称函数，可表示为某个特征映射 ϕ 的内积:*

$$k(\boldsymbol{x}_i, \boldsymbol{x}_j) = \langle \phi(\boldsymbol{x}_i), \phi(\boldsymbol{x}_j) \rangle$$

定理 21.3 (核化 SVM). *在 SVM 对偶问题中，将内积 $\boldsymbol{x}_i^T\boldsymbol{x}_j$ 替换为核函数 $k(\boldsymbol{x}_i, \boldsymbol{x}_j)$，即可在特征空间中学习线性分类器，等价于原空间中的非线性分类器。*

例 21.1 (常用核函数).

- *线性核: $k(\boldsymbol{x}, \boldsymbol{x}') = \boldsymbol{x}^T\boldsymbol{x}'$;*
- *多项式核: $k(\boldsymbol{x}, \boldsymbol{x}') = (\boldsymbol{x}^T\boldsymbol{x}' + c)^d$;*
- *RBF 核（高斯核）: $k(\boldsymbol{x}, \boldsymbol{x}') = \exp\left(-\frac{\|\boldsymbol{x}-\boldsymbol{x}'\|^2}{2\sigma^2}\right)$。*

21.3 工程易错

- 软间隔 SVM 引入松弛变量 ξ_i 和惩罚参数 C，对偶中 $0 \le \alpha_i \le C$。
- SVM 输出为距离，需通过 Platt 缩放（用 sigmoid 拟合）转换为概率。
- 核函数需满足 Mercer 条件，常见选择：线性核、多项式核、RBF 核。

21.4 前沿

深度学习时代，SVM 仍用于小样本场景，或作为神经网络顶层分类器（用预训练特征）。此外，SVM 的 hinge 损失也被用于深度网络的目标函数，如 Crammer-Singer 多分类 SVM。

22 K-均值聚类

22.1 算法

定义 22.1 (K-均值目标函数)**.** *给定数据集 $\{\boldsymbol{x}_1, \ldots, \boldsymbol{x}_n\}$，$K$-均值聚类最小化簇内平方和：*

$$J = \min_{\{C_1,\ldots,C_k\}} \sum_{j=1}^{k} \sum_{\boldsymbol{x} \in C_j} \|\boldsymbol{x} - \boldsymbol{\mu}_j\|^2$$

其中 $\boldsymbol{\mu}_j = \frac{1}{|C_j|} \sum_{\boldsymbol{x} \in C_j} \boldsymbol{x}$ 为簇 C_j 的中心。

定理 22.1 (K-均值的交替优化)**.** *K-均值算法交替执行以下两步：*

1. **分配步骤**：*固定中心，将每个样本分配到最近的簇：*

$$C_j^{(t)} = \{\boldsymbol{x}_i : \|\boldsymbol{x}_i - \boldsymbol{\mu}_j^{(t)}\| \le \|\boldsymbol{x}_i - \boldsymbol{\mu}_l^{(t)}\|, \forall l \ne j\}$$

2. **更新步骤**：*固定分配，更新中心：*

$$\boldsymbol{\mu}_j^{(t+1)} = \frac{1}{|C_j^{(t)}|} \sum_{\boldsymbol{x} \in C_j^{(t)}} \boldsymbol{x}$$

每步都使目标函数非增，故算法收敛到局部最优。

22.2 工程易错

- 初始化敏感：常用 k-means++（选择离已有中心远的点作为新中心）。
- 需预设 k，可用肘部法则、轮廓系数等选择。
- 假设簇为凸形，对非球形簇效果差，可用谱聚类或高斯混合模型。
- 可能收敛到局部最优，应多次运行取最佳。

22.3 前沿

- 深度聚类：结合自编码器提取特征再聚类，或端到端联合优化（如 DEC）。
- 在自监督学习中，k-means 用于生成伪标签（如 SwAV）。

23 局部核、流形假设与流形学习

23.1 局部核

定义 23.1 (局部核). 局部核是指核值随输入距离增大而衰减的核函数。典型例子是高斯核（RBF 核）：

$$k(\boldsymbol{x}, \boldsymbol{x}') = \exp\left(-\frac{\|\boldsymbol{x} - \boldsymbol{x}'\|^2}{2\sigma^2}\right)$$

当 $\|\boldsymbol{x} - \boldsymbol{x}'\| \to \infty$ 时，$k(\boldsymbol{x}, \boldsymbol{x}') \to 0$，体现局部平滑先验。

23.2 流形假设

定义 23.2 (流形假设). 流形假设认为：高维观测数据实际位于或接近某个嵌入在高维空间的低维流形上。形式化地，设数据空间为 $\mathbb{R}^D$，存在低维流形 $\mathcal{M}$（维度 $d \ll D$），使得数据点 $\boldsymbol{x} \approx \boldsymbol{m}$，$\boldsymbol{m} \in \mathcal{M}$。

注 23.1 (流形假设的意义).

- 解释了为什么高维数据中存在大量冗余和相关性；
- 为降维和特征学习提供理论基础；
- 深度网络的表示学习可视为学习数据的流形结构。

23.3 流形学习算法

例 23.1 (经典流形学习方法).

- ***LLE*（局部线性嵌入）**：假设每个数据点可由邻居线性重构，保持重构系数。设 $\boldsymbol{x}_i = \sum_{j \in \mathcal{N}(i)} w_{ij} \boldsymbol{x}_j$，则嵌入 $\boldsymbol{y}_i$ 满足 $\boldsymbol{y}_i = \sum_{j \in \mathcal{N}(i)} w_{ij} \boldsymbol{y}_j$。
- ***Isomap***：用测地距离替代欧氏距离，保持全局流形结构。通过构建邻接图并计算最短路径来估计测地距离。
- ***t-SNE***：将高维相似度映射为低维 t 分布相似度，用于可视化。目标是最小化 KL 散度：

$$KL(P\|Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

23.4 工程易错

- 流形学习对噪声敏感，需预处理。
- t-SNE 计算复杂度高，适用于小样本可视化；近年有 UMAP 等改进。

23.5 前沿与深度学习

注 23.2 (深度学习与流形).

- **深度自编码器**：通过瓶颈层强制学习低维表示，隐式学习数据的流形结构；
- **生成对抗网络（*GAN*）**：生成样本位于学习到的流形上，判别器学习区分真实流形和生成流形；
- **流形正则化**：在半监督学习中，利用流形假设添加平滑性约束，如拉普拉斯正则化：

$$\mathcal{R} = \sum_{i,j} w_{ij} \|f(\boldsymbol{x}_i) - f(\boldsymbol{x}_j)\|^2$$

  其中 w_{ij} 为样本相似度；
- **神经流形假设**：神经网络内部表示位于低维流形上，可用于解释泛化和指导模型压缩。